

UNIVERSIDADE FEDERAL DE PERNAMBUCO
CENTRO DE INFORMÁTICA
APRENDIZAGEM DE MÁQUINA – 2026.2

BRUNA ISABEL SANTOS CRUZ
EVERTHON MANOEL DA SILVA INACIO
ANA CAROLINA SOARES DE MELO

Double k-means e classificadores bayesianos, logístico e por voto majoritário na base Spambase

Relatório do projeto da disciplina de Aprendizagem de Máquina do Centro de Informática da Universidade Federal de Pernambuco, elaborado por estudantes de mestrado do CIn/UFPE.

Professor Prof. Francisco de A. T. de Carvalho

Recife
2026

RESUMO

O presente relatório descreve os experimentos do projeto da disciplina de Aprendizagem de Máquina sobre a base Spambase (4.601 e-mails, 57 atributos contínuos). Na Questão 1, o algoritmo double k-means foi executado 100 vezes para cada um dos 9 pares (K, H) com $K \in \{2, 3, 4\}$ e $H \in \{1, \ldots, K\}$; a melhor execução de cada par, segundo a função objetivo, foi comparada pela silhueta, que selecionou $(K^*, H^*) = (2, 2)$ (Sil $= 0{,}6596$). A partição resultante isola 34 e-mails legítimos com valores extremos em 11 atributos ligados à HP e tem índice de Rand corrigido ARI $= -0{,}00495$ em relação às classes a priori. Na Questão 2, cinco classificadores (bayesiano gaussiano, bayesiano k-NN, bayesiano com janela de Parzen, regressão logística e voto majoritário) foram avaliados nas duas versões da base (rótulo original e rótulo dado pelos K^* grupos) por validação cruzada estratificada 30×10 com ajuste de hiperparâmetros por validação cruzada interna de 5 folds, intervalos de confiança, testes de Friedman e Nemenyi e curvas de aprendizagem. Na base original, voto majoritário ($F = 0{,}9238$) e regressão logística ($F = 0{,}9230$) não diferem significativamente entre si e superam os demais.

SUMÁRIO

1 Introdução **4**

2 Descrição dos dados **4**

3 Organização dos experimentos **5**

4 Questão 1: double k-means **6**
4.1 O algoritmo 6
4.2 Protocolo 6
4.3 Seleção de (K, H) 7
4.4 Partição selecionada 8
4.5 Discussão 10

5 Questão 2: classificação supervisionada **11**
5.1 Versões da base 11
5.2 Classificadores 11
5.3 Protocolo de avaliação: validação cruzada 30×10 com ajuste interno 12
5.4 Métricas 13
5.5 Obtenção dos hiperparâmetros 13
5.6 Estimativas pontuais e intervalos de confiança 15
5.7 Testes de Friedman e Nemenyi 17
5.8 Curvas de aprendizagem 18

6 Discussão e limitações **22**

7 Conclusões **22**

Referências **23**

A Reprodução dos resultados **25**

1 Introdução

O projeto possui duas partes, sendo a primeira relativa à Questão 1, de natureza não supervisionada, na qual o double k-means [1] é aplicado para agrupar ao mesmo tempo os objetos e as variáveis da Spambase, o número de grupos de objetos K^* é escolhido pela silhueta [2] e a partição obtida é comparada com as classes a priori pelo índice de Rand corrigido [3]. Já a segunta parte, que trata da Questão 2, de natureza supervisionada, onde cinco classificadores são avaliados e comparados em duas versões da base, uma com o rótulo original (spam/não spam) e outra com o rótulo dado pela partição de K^* grupos da Questão 1.

Atendendo às observações finais do enunciado, o relatório dá destaque a três pontos: a organização dos experimentos que garante uma avaliação sem vazamento de informação e uma comparação pareada entre os modelos (Seção 3), a descrição dos dados (Seção 2) e a obtenção dos hiperparâmetros (Seção 5.5). A Seção 4 trata da Questão 1, a Seção 5 da Questão 2, a Seção 6 discute limitações e a Seção 7 traz a conclusão do trabalho. Todo o código está no repositório do projeto, além disso, o Apêndice A lista os comandos que geram cada resultado.

2 Descrição dos dados

A base Spambase [4], do repositório UCI, contém $n = 4.601$ e-mails, sem valores ausentes, descritos por uma variável resposta binária (1 = spam, 0 = não spam) e por $d = 57$ atributos contínuos, que formam os três grupos da Tabela 1.

Tabela 1: Grupos de atributos da Spambase.

Grupo	Qtd.	Descrição
`word_freq_*`	48	Percentual ($[0, 100]$) de palavras do e-mail iguais a uma palavra dada (p. ex. *make*, *free*, *money*, *hp*, *george*, *650*).
`char_freq_*`	6	Percentual ($[0, 100]$) de caracteres iguais a `;`, `(`, `[`, `!`, `$` e `#`.
`capital_run_length_*`	3	Comprimento médio (*average*) e máximo (*longest*) das sequências de letras maiúsculas e número total de maiúsculas (*total*); valores ≥ 1.

As características abaixo foram levantadas na base completa e orientaram decisões dos experimentos:

- **Classes moderadamente desbalanceadas:** 2.788 e-mails não spam (60,6 %) e 1.813 spam (39,4 %), razão pela qual todas as partições de treino e teste foram estratificadas.
- **Escalas muito diferentes:** os desvios-padrão dos atributos vão de 0,076 a 606,3. As frequências ficam quase sempre abaixo de 10, enquanto `capital_run_length_total` chega a 15.841 (mediana 95). Métodos baseados em distância ou com penalização dos coeficientes dependem da escala, o que motivou a padronização z-score na Questão 1 e dentro dos modelos k-NN e regressão logística na Questão 2.
- **Esparsidade e assimetria:** 77,4 % das entradas da matriz são zero, já que 50 dos 57 atributos têm mais de metade dos valores iguais a zero e 19 têm mais de 90 %, e a assimetria amostral mediana dos atributos chega a 9,7. A hipótese de normalidade multivariada do classificador gaussiano é, portanto, pouco realista, e em amostras pequenas alguns atributos ficam constantes, o que torna as covariâncias singulares (Seção 5.2).
- **Linhas duplicadas:** há 391 linhas idênticas (atributos e rótulo) a alguma linha anterior. Como a base original foi mantida intacta, cópias idênticas podem cair uma no treino e outra no teste, o que favorece levemente os métodos de vizinhança (Seção 6).
- **Origem dos e-mails legítimos:** segundo a documentação da base, os e-mails não spam vieram da correspondência de trabalho e pessoal dos autores na Hewlett-Packard, de modo

que palavras como *george* e o código de área *650* indicam não spam [4], fato que explica o grupo de variáveis encontrado na Questão 1.

A segunda versão da base, usada na Questão 2, mantém os mesmos 57 atributos e troca a variável resposta pela partição de objetos com $K^* = 2$ grupos obtida na Questão 1: 4.567 objetos (99,26 %) no grupo P_1 e 34 (0,74 %) no grupo P_2 (Seção 4.4). Essa versão é extremamente desbalanceada: um classificador que sempre prediz o grupo majoritário erra apenas 0,74 % dos exemplos.

3 Organização dos experimentos

A Figura 1 resume o encadeamento dos experimentos: a Questão 1 usa apenas os atributos e produz os rótulos y^* da segunda versão da base, enquanto e a Questão 2 avalia os classificadores nas duas versões com o mesmo protocolo.

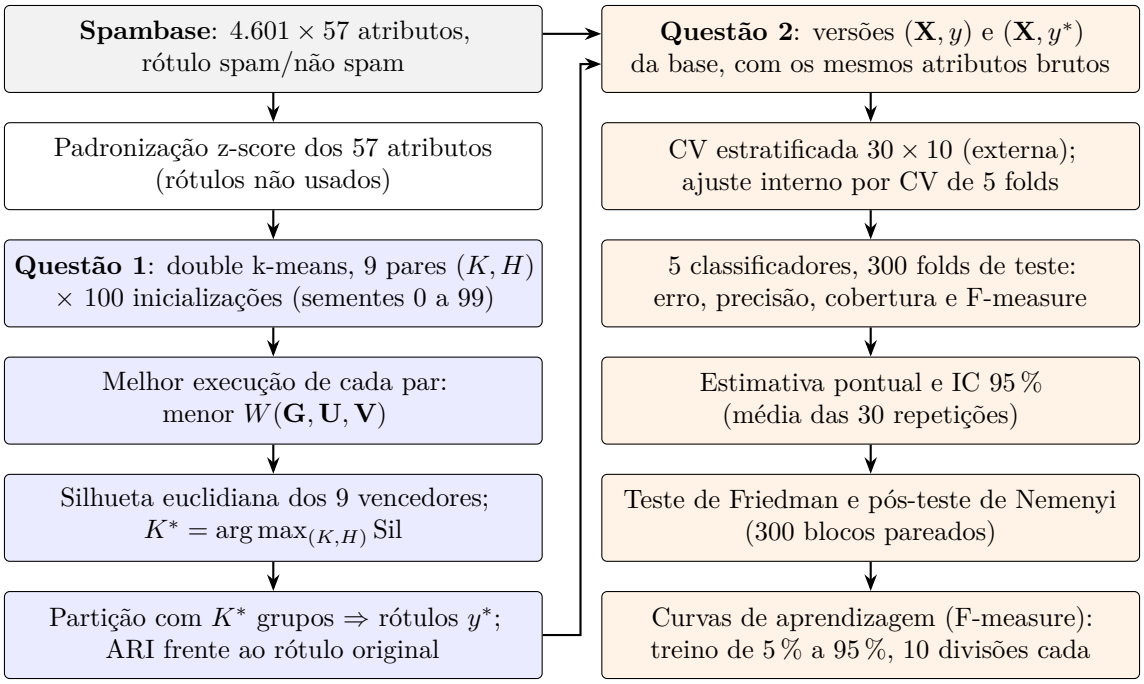


Figura 1: Encadeamento dos experimentos. A coluna da esquerda produz os rótulos y^* usados na segunda versão da base; a coluna da direita é executada igualmente para as duas versões. As curvas de aprendizagem usam divisões próprias, independentes da validação cruzada 30 × 10.

Os experimentos seguem cinco princípios, adotados para que a avaliação de cada modelo seja correta e a comparação entre eles seja justa:

1. **Separação entre seleção e avaliação.** Os hiperparâmetros são escolhidos apenas com os dados de aprendizagem de cada fold externo, por uma validação cruzada interna; o fold de teste só é usado uma vez, para medir o modelo já ajustado. Escolher hiperparâmetros e medir o desempenho nos mesmos dados produz estimativas otimistas [5], [6].
2. **Pré-processamento dentro do treino.** A padronização usada pelo k-NN e pela regressão logística faz parte do próprio modelo: média e desvio são estimados no conjunto em que o modelo é ajustado (cada fold interno na seleção, os 9 folds no reajuste final) e apenas aplicados ao conjunto de validação ou teste.
3. **Comparação pareada.** Os cinco classificadores são avaliados exatamente nas mesmas 300 partições externas e, dentro de cada uma, nas mesmas 5 partições internas. As diferenças

entre eles refletem os modelos, e não sorteios diferentes, e cada fold externo forma um bloco para o teste de Friedman [7] (ver a ressalva na Seção 5.7).

4. **Estratificação.** Todas as divisões (externas, internas e das curvas de aprendizagem) preservam as proporções das classes, o que reduz a variância das estimativas [8] e é indispensável na versão com K^* grupos, cuja classe rara tem 34 exemplos.
5. **Reprodutibilidade.** Todas as fontes de aleatoriedade têm semente fixa (Tabela 2) e os resultados brutos de cada execução e de cada fold são salvos em `results/`.

Tabela 2: Fontes de aleatoriedade e sementes. No double k-means, cada uma das 100 execuções de um par usa uma semente; na CV interna das curvas, $r = 0, \ldots, 9$ é o índice da divisão.

Etapa	Procedimento	Semente
Q1, double k-means	Partições iniciais aleatórias de objetos e variáveis	0 a 99
Q2, CV externa	`RepeatedStratifiedKFold`, 10 folds × 30 repetições	42
Q2, CV interna	`StratifiedKFold`, 5 folds com embaralhamento	42
Q2, regressão logística	Semente do otimizador (`lbfgs` é determinístico)	42
Curvas de aprendizagem	`StratifiedShuffleSplit`, 10 divisões por proporção	42
Curvas, CV interna	`StratifiedKFold` com $\min(5, n_{\min})$ folds	$42 + r$

4 Questão 1: double k-means

4.1 O algoritmo

O double k-means [1] é um método de agrupamento simultâneo de objetos e variáveis (*co-clustering*) [9]. Dada a matriz $\mathbf{X} = (x_{ij})$, $n \times d$, ele obtém uma partição exclusiva dos objetos em K grupos $P_1, \ldots, P_K$ (matriz indicadora $\mathbf{U} = (u_{ik})$), uma partição exclusiva das variáveis em H grupos $Q_1, \ldots, Q_H$ (matriz indicadora $\mathbf{V} = (v_{jh})$) e uma matriz de protótipos $\mathbf{G} = (g_{kh})$, $K \times H$, um valor por bloco, que minimizam

$$W(\mathbf{G}, \mathbf{U}, \mathbf{V}) = \sum_{k=1}^{K} \sum_{h=1}^{H} \sum_{i=1}^{n} \sum_{j=1}^{d} u_{ik}\, v_{jh}\, (x_{ij} - g_{kh})^2. \tag{1}$$

Partindo de partições aleatórias, o algoritmo alterna três passos até que nenhum objeto e nenhuma variável mude de grupo, como foi visto na disciplina:

1. com $\mathbf{U}$ e $\mathbf{V}$ fixos, $g_{kh} = \frac{1}{n_k n_h} \sum_i \sum_j u_{ik} v_{jh} x_{ij}$ (média do bloco kh);
2. com $\mathbf{G}$ e $\mathbf{V}$ fixos, cada objeto vai para o grupo k que minimiza $\sum_h \sum_j v_{jh}(x_{ij} - g_{kh})^2$;
3. com $\mathbf{G}$ e $\mathbf{U}$ fixos, cada variável vai para o grupo h que minimiza $\sum_k \sum_i u_{ik}(x_{ij} - g_{kh})^2$.

Para o tratamento de empates e de grupos que fiquem vazios, adotou-se na implementação duas regras: (a) Um item só muda de grupo se o custo cair mais de 10^{-9} (melhora estrita, como em Hartigan e Wong [10]), o que impede trocas causadas por arredondamento, e (b) um grupo esvaziado nos passos 2 ou 3 recebe o item de maior custo em relação ao próprio protótipo, escolhido entre os grupos com pelo menos dois membros, a mesma estratégia do k-means do scikit-learn. Com essas regras W nunca aumenta, toda execução termina com exatamente K e H grupos e nenhuma precisa ser descartada. O limite de 100 iterações é só uma salvaguarda: as 900 execuções convergiram pelo critério dos slides.

4.2 Protocolo

- **Pré-processamento:** foi realizada a padronização z-score de cada atributo na base completa, pois sem a mesma, W seria dominado pelos atributos `capital_run_length_*`,

cuja variância é milhares de vezes maior que a das frequências, e as variáveis seriam agrupadas pela escala. O rótulo spam/não spam não entra no agrupamento, de forma que padronizar com a base completa não introduz vazamento.

- **Grade:** $K \in \{2,3,4\}$ e $H \in \{1,\dots,K\}$, isto é, 9 pares: $(2,1)$, $(2,2)$, $(3,1)$, $(3,2)$, $(3,3)$, $(4,1)$, $(4,2)$, $(4,3)$ e $(4,4)$.
- **Repetições:** 100 execuções por par a partir de inicializações aleatórias (sementes 0 a 99), 900 no total. Como o algoritmo só garante um mínimo local, a solução de cada par é a execução de menor W (em caso de empate exato, a de menor semente).
- **Escolha de K^*:** W não serve para comparar pares diferentes, porque diminui quando K e H aumentam (há mais protótipos para ajustar). Consequentemente, calculou-se a silhueta da partição de objetos de cada um dos 9 vencedores e escolheu-se K^* pelo par de maior silhueta. A silhueta de um objeto i é $s(i) = \frac{b(i)-a(i)}{\max\{a(i),b(i)\}}$, em que $a(i)$ é a distância média de i aos objetos do seu grupo e $b(i)$ a menor distância média de i aos objetos de outro grupo; Sil é a média de $s(i)$ sobre os n objetos [2]. Usou-se a distância euclidiana nos 57 atributos padronizados, o mesmo espaço em que o algoritmo foi executado.
- **Avaliação externa:** índice de Rand corrigido [3] entre a partição de objetos com K^* grupos e as classes a priori. Com n_{ij} a tabela de contingência, a_i e b_j seus totais marginais,

$$\mathrm{ARI} = \frac{\sum_{ij}\binom{n_{ij}}{2} - \Big[\sum_i \binom{a_i}{2}\sum_j \binom{b_j}{2}\Big]\Big/\binom{n}{2}}{\frac{1}{2}\Big[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}\Big] - \Big[\sum_i \binom{a_i}{2}\sum_j \binom{b_j}{2}\Big]\Big/\binom{n}{2}}. \tag{2}$$

  O ARI vale 1 para partições idênticas e tem valor esperado 0 quando as partições são independentes; valores negativos indicam concordância abaixo da esperada ao acaso.

4.3 Seleção de (K, H)

A Tabela 3 traz, para cada par, a melhor execução e sua silhueta, e a Figura 2 mostra o gráfico Sil $\times$ (K, H) pedido no enunciado.

Tabela 3: Melhor das 100 execuções de cada par (K, H) e silhueta da sua partição de objetos; todas as 900 execuções convergiram.

K	H	Menor W	Semente	Iterações	Sil
2	1	256.513,75	0	11	0,2961
2	**2**	**244.486,70**	**0**	**31**	**0,6596**
3	1	254.414,01	0	40	0,2515
3	2	239.421,79	82	40	0,2367
3	3	234.585,87	7	30	0,1409
4	1	253.278,68	0	38	0,0484
4	2	233.358,70	3	43	0,2428
4	3	228.516,44	8	26	0,1620
4	4	227.250,88	18	28	0,1775

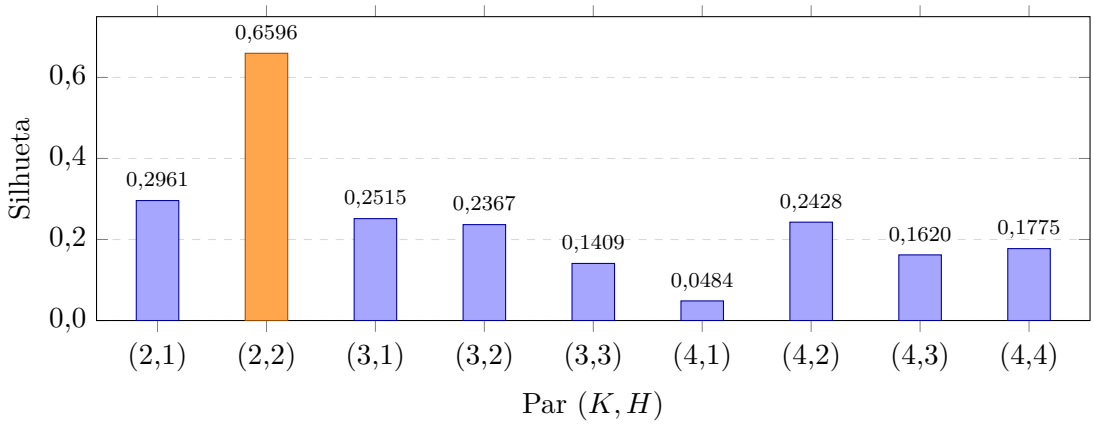


Figura 2: Silhueta da melhor partição (menor W) de cada par (K, H). O máximo ocorre em $(2, 2)$, logo $K^* = 2$ (e $H^* = 2$).

O par $(2, 2)$ tem silhueta 0,6596, mais que o dobro da segunda maior (0,2961, em $(2, 1)$), e foi selecionado: $K^* = 2$. Na escala de interpretação de Kaufman e Rousseeuw [11], 0,66 indica uma estrutura razoável, enquanto os demais pares, entre 0,05 e 0,30, ficam nas faixas de estrutura fraca ou inexistente. Note também que, como esperado, o menor W cai quando K e H crescem, de 256.513,75 em $(2, 1)$ a 227.250,88 em $(4, 4)$.

As partições dos outros pares ajudam a entender a escolha: com $K \geq 3$, o grupo dos 34 e-mails descrito na Seção 4.4 reaparece, inteiro em $(3, 2)$ e $(3, 3)$ e quase inteiro nos demais, e o restante da base é dividido em dois ou três grupos grandes (por exemplo, 3.437 e 1.130 objetos em $(3, 2)$). Essa divisão da massa principal não tem separação nítida e derruba a silhueta, que fica entre 0,05 e 0,25 para $K \geq 3$. Já em $(2, 1)$, com um único grupo de variáveis, os 34 e-mails ficam diluídos num grupo de 1.018 objetos, e a silhueta não passa de 0,30.

4.4 Partição selecionada

A melhor execução de $(K^*, H^*) = (2, 2)$, com semente 0, separa as variáveis em um grupo Q_1 com 11 atributos, *hp*, *hpl*, *650*, *lab*, *labs*, *telnet*, *857*, *415*, *85*, *technology* e *direct*, e um grupo Q_2 com os outros 46 (37 palavras, os 6 caracteres e os 3 atributos de maiúsculas). Os 11 atributos de Q_1 são nomes e números ligados aos laboratórios da HP em Palo Alto (códigos de área 650 e 415), a origem dos e-mails legítimos da base. Os objetos ficam em um grupo P_1 com 4.567 e-mails e um grupo P_2 com 34,[1] cujos protótipos, em unidades de desvio-padrão, formam a matriz $\mathbf{G}$ da Tabela 4.

Tabela 4: Matriz de protótipos dos blocos $\mathbf{G}$ para $(K^*, H^*) = (2, 2)$ (atributos padronizados).

	Q_1 (11 variáveis HP)	Q_2 (46 variáveis)	Objetos
P_1	−0,0511	0,0011	4.567
P_2	6,8612	−0,1444	34

O bloco $P_2 \times Q_1$ tem protótipo 6,86: os 34 e-mails de P_2 usam as 11 palavras da HP, em média, quase sete desvios-padrão acima da média da base, enquanto nas demais variáveis (Q_2) ficam ligeiramente abaixo dela (−0,14). O grupo P_1, por sua vez, tem protótipos próximos de zero nos dois blocos, ou seja, reúne o restante da base sem distinção.

[1] No código e nos arquivos de resultados, os grupos P_1, P_2 e Q_1, Q_2 aparecem com os rótulos 0 e 1.

Tabela 5: Matriz de confusão (contingência) entre a partição de objetos do double k-means e as classes a priori.

Classe a priori	P_1	P_2	Total
Não spam (0)	2.754	34	2.788
Spam (1)	1.813	0	1.813
Total	4.567	34	4.601

Quando essa partição é cruzada com as classes a priori (Tabela 5), os 34 e-mails de P_2 são todos não spam e P_1 reúne os 1.813 spam e os outros 2.754 não spam, o que resulta em um índice de Rand corrigido de ARI $= -0{,}00495$ entre as duas partições.

A completar: Comentário sobre o ARI com Bruna e Everthon. Interpretar o valor ARI $= -0{,}00495$ à luz da Tabela 5 e da matriz **G**: a. o que significa um ARI próximo de zero e negativo; b. por que ele é compatível com uma silhueta alta; c. o que a partição encontrada revela sobre a estrutura da base.

Um ARI tão próximo de zero indica que a partição obtida não guarda relação com as classes spam/não spam, pois a concordância entre as duas é praticamente a que se esperaria de partições independentes: o único corte feito pelo double k-means passa por dentro da classe não spam, deixando todo o spam misturado ao restante em P_1, de modo que a pureza da partição (60,6 %) é exatamente a proporção da classe majoritária. O sinal negativo decorre da composição de P_2, porque um grupo de 34 e-mails sorteados ao acaso teria, em média, cerca de 21 não spam e 13 spam, e separá-lo do restante desfaria cerca de 81 mil pares de e-mails da mesma classe, ao passo que P_2, formado apenas por não spam, desfaz $34 \times 2.754 = 93.636$ desses pares, o que deixa a concordância com as classes ligeiramente abaixo da esperada ao acaso.

Esse valor é compatível com a silhueta alta porque os dois índices medem propriedades diferentes: a silhueta é um critério interno, calculado apenas com as distâncias entre os objetos, e é elevada porque P_2 está, em média, 6,86 desvios-padrão acima da média nas 11 variáveis de Q_1 (Tabela 4), o que torna $s(i)$ alto para quase todos os objetos de P_1 (Seção 4.5), enquanto o ARI é um critério externo, que compara a partição com um rótulo que o algoritmo nunca utilizou. A partição revela, portanto, que a estrutura geométrica dominante na base padronizada não é a divisão entre spam e não spam, mas um pequeno grupo de e-mails internos da HP com uso intenso de termos como *hp*, *hpl*, *650* e *lab*, reflexo da forma como os e-mails legítimos da base foram coletados (Seção 2). A diferença entre as classes está em direções mais sutis do espaço de atributos, que o agrupamento não captura, mas que os classificadores supervisionados da Questão 2 exploram, com F-measure macro de 0,923 na regressão logística (Tabela 9).

A Figura 3 mostra a função objetivo ao longo das iterações da execução selecionada. W parte de 262.251,38 na partição inicial e decresce monotonamente até 244.486,70, quando nenhum objeto ou variável muda de grupo (iteração 31, que repete o valor da 30). Entre as iterações 11 e 20 há um patamar em que W quase não varia, seguido de uma nova queda até a convergência: o algoritmo pode passar várias iterações com transferências de pouco ganho antes de encontrar uma reorganização que reduz W de forma apreciável.

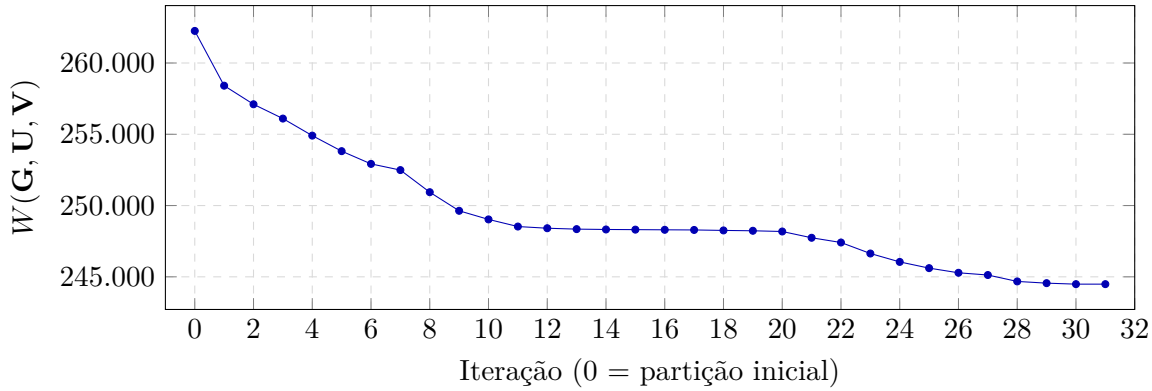


Figura 3: Função objetivo versus iterações na melhor execução de $(K^*, H^*) = (2, 2)$. Cada ponto é W com a partição do fim da iteração e os protótipos ótimos para ela.

4.5 Discussão

A silhueta escolheu uma partição muito desbalanceada porque, sendo Sil a média de $s(i)$ sobre todos os objetos, 99,26 % dos termos dessa média vêm de objetos de P_1. Para cada um deles, $a(i)$ é a distância média ao grosso da base, e $b(i)$ é a distância média aos 34 objetos de P_2, que estão, em média, quase sete desvios-padrão acima da média em 11 variáveis (Tabela 4); assim, $b(i)$ tende a ser bem maior que $a(i)$ e $s(i)$ fica alto. A silhueta premia, portanto, a separação de um pequeno grupo atípico, e não uma divisão equilibrada da base. Esse comportamento é coerente com duas limitações do double k-means apontadas nos slides da disciplina, a sensibilidade a valores discrepantes e a preferência por grupos compactos e esféricos, e com o fato de a soma de quadrados dar peso desproporcional às caudas longas dos atributos esparsos (Seção 2). Para a Questão 2, a consequência é que a segunda versão da base pede a distinção entre esses 34 e-mails e o restante, uma tarefa diferente e muito mais desbalanceada que a detecção de spam.

Essa tarefa tem, além disso, uma fronteira linear conhecida, porque, na convergência, cada objeto está no grupo de menor custo do passo 2, dados $\mathbf{G}$ e $\mathbf{V}$. Com $\mathbf{z}_i$ o vetor padronizado do objeto i, $c_k(\mathbf{z}_i)$ o custo de colocá-lo no grupo k e d_h o número de variáveis de Q_h, os termos z_{ij}^2 se cancelam na diferença entre os custos dos dois grupos, que é linear em $\mathbf{z}_i$:

$$c_1(\mathbf{z}_i) - c_2(\mathbf{z}_i) = \sum_{h=1}^{H} \Big[2\,(g_{2h} - g_{1h})\, S_{ih} - d_h\,(g_{2h}^2 - g_{1h}^2) \Big], \qquad S_{ih} = \sum_{j \in Q_h} z_{ij}. \tag{3}$$

Com os valores da Tabela 4, o objeto vai para P_2 se e somente se $S_{i1} - 0{,}021\, S_{i2} > 37{,}5$, isto é, quando a soma das 11 variáveis da HP padronizadas passa de cerca de 37,5 (em média, mais de 3,4 desvios-padrão por variável). Aplicada aos dados padronizados, essa regra reproduz exatamente os 4.601 rótulos, de modo que as duas classes da versão `kstar_classes` são linearmente separáveis no espaço padronizado e também no espaço original, já que a padronização é uma transformação afim.

5 Questão 2: classificação supervisionada

5.1 Versões da base

Tabela 6: Versões da base usadas na Questão 2. Os atributos são os 57 originais, sem transformação prévia.

Versão	Variável resposta	Classe 0	Classe 1
`original_2_classes`	spam/não spam (a priori)	2.788 (60,6 %)	1.813 (39,4 %)
`kstar_classes`	grupos P_1/P_2 da Questão 1 ($K^* = 2$)	4.567 (99,26 %)	34 (0,74 %)

Como $K^* = 2$, a segunda versão também é binária, e a sua classe rara tem apenas 3 ou 4 exemplos nos folds externos de teste (≈ 460 exemplos) e cerca de 30 nos folds de aprendizagem (≈ 4.141 exemplos).

5.2 Classificadores

Todos os classificadores seguem a interface do scikit-learn [12]; os quatro primeiros correspondem às regras pedidas no enunciado, e o quinto combina os quatro.

i) Bayesiano gaussiano. Atribui $\mathbf{x}$ à classe ω_l de maior posteriori $P(\omega_l \mid \mathbf{x}) \propto p(\mathbf{x} \mid \omega_l)\, P(\omega_l)$, com estimativas de máxima verossimilhança [13]

$$\hat{P}(\omega_i) = \frac{n_i}{n}, \qquad \hat{\boldsymbol{\mu}}_i = \frac{1}{n_i} \sum_{\mathbf{x}_k \in \omega_i} \mathbf{x}_k, \qquad \hat{\boldsymbol{\Sigma}}_i = \frac{1}{n_i} \sum_{\mathbf{x}_k \in \omega_i} (\mathbf{x}_k - \hat{\boldsymbol{\mu}}_i)(\mathbf{x}_k - \hat{\boldsymbol{\mu}}_i)^\top, \tag{4}$$

e densidade normal multivariada. A decisão é tomada em escala logarítmica,

$$\hat{\omega}(\mathbf{x}) = \arg\max_i \Big[\ln \hat{P}(\omega_i) - \tfrac{1}{2} \ln \big|\tilde{\boldsymbol{\Sigma}}_i\big| - \tfrac{1}{2} (\mathbf{x} - \hat{\boldsymbol{\mu}}_i)^\top \tilde{\boldsymbol{\Sigma}}_i^{-1} (\mathbf{x} - \hat{\boldsymbol{\mu}}_i) \Big], \qquad \tilde{\boldsymbol{\Sigma}}_i = \hat{\boldsymbol{\Sigma}}_i + \varepsilon \mathbf{I}, \tag{5}$$

com o determinante e a forma quadrática calculados pela fatoração de Cholesky de $\tilde{\boldsymbol{\Sigma}}_i$. O termo $\varepsilon\mathbf{I}$, com $\varepsilon = 10^{-6}$ fixo, foi necessário porque a estimativa de máxima verossimilhança é singular nas duas versões da base. Em `kstar_classes`, a classe rara tem cerca de 30 exemplos de treino para $d = 57$ atributos, e $\operatorname{posto}(\hat{\boldsymbol{\Sigma}}_i) \le n_i - 1 < d$; além disso, os 34 e-mails de P_2 são todos não spam, só 28 deles são distintos e 29 dos 57 atributos são nulos em todos eles, de modo que a covariância estimada com os 34 tem posto 16. Na base original, `word_freq_cs` é não nulo em apenas 1 dos 1.813 e-mails spam, e `word_freq_857` em apenas 2. Sempre que esses exemplos ficam fora do treino, o atributo é constante na classe spam e $\hat{\boldsymbol{\Sigma}}_i$ é singular. Isso ocorre em pelo menos 30 dos 300 folds externos (em cada repetição, o fold cujo teste contém o único spam com `word_freq_cs` não nulo), em parte dos folds internos e na maior parte das divisões com treino pequeno da curva de aprendizagem, casos em que, sem a correção, a densidade não estaria definida. O valor $\varepsilon = 10^{-6}$ é o padrão do parâmetro `reg_covar` do `GaussianMixture` do scikit-learn e é muito menor que a menor variância dos atributos ($0{,}076^2 \approx 0{,}0058$), de modo que só altera de forma apreciável as direções de variância nula. Trata-se de uma forma mínima da regularização por encolhimento da covariância [14], [15] e, como ε não é ajustado, o classificador continua sem hiperparâmetros.

ii) Bayesiano baseado em k vizinhos. Estimando $p(\mathbf{x} \mid \omega_i) = k_i/(n_i V)$, em que V é o volume da menor vizinhança de $\mathbf{x}$ que contém k exemplos de treino e k_i deles são da classe ω_i, e $\hat{P}(\omega_i) = n_i/n$, a regra de Bayes se reduz a $P(\omega_i \mid \mathbf{x}) = k_i/k$, isto é, ao voto majoritário entre os k vizinhos [13], [16]. A vizinhança é definida pela distância euclidiana, city-block (L_1) ou Chebyshev (L_∞), calculada sobre os atributos padronizados (z-score estimado no conjunto de treino), e tanto essa distância quanto o número de vizinhos k são hiperparâmetros.

iii) Bayesiano com janela de Parzen. A densidade de cada classe é estimada pelo kernel multivariado produto com kernel gaussiano univariado e a mesma janela h em todas as dimensões [13], [17],

$$\hat{p}(\mathbf{x} \mid \omega_i) = \frac{1}{n_i} \sum_{\mathbf{x}_m \in \omega_i} \prod_{j=1}^{d} \frac{1}{h}\, \phi\!\left(\frac{x_j - x_{mj}}{h}\right) = \frac{1}{n_i (2\pi)^{d/2} h^d} \sum_{\mathbf{x}_m \in \omega_i} \exp\!\left(-\frac{\|\mathbf{x} - \mathbf{x}_m\|^2}{2h^2}\right), \qquad (6)$$

com ϕ a densidade normal padrão e $\hat{P}(\omega_i) = n_i/n$; a decisão maximiza $\ln \hat{p}(\mathbf{x} \mid \omega_i) + \ln \hat{P}(\omega_i)$. A janela h é o único hiperparâmetro e, nesta implementação, o estimador recebe os atributos na escala original (Seção 6).

iv) Regressão logística. Modelo discriminativo $P(\omega_1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{z} + b)$, em que $\mathbf{z}$ são os atributos padronizados no treino e σ é a função logística, ajustado por máxima verossimilhança penalizada [15]: $\min_{\mathbf{w},b}\ \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_k \ell(y_k, \mathbf{x}_k)$, com ℓ a perda logística, otimizador L-BFGS e até 10.000 iterações [12], tendo como hiperparâmetro o inverso da força de regularização, C.

v) Voto majoritário. Combina os rótulos preditos pelos quatro classificadores anteriores, $\hat{\omega}(\mathbf{x}) = \arg\max_c \sum_{m=1}^{4} \mathbf{1}[\hat{\omega}_m(\mathbf{x}) = c]$ [18]. Cada membro entra com os hiperparâmetros que ele mesmo selecionou na validação cruzada interna do fold externo corrente; o comitê, portanto, não tem hiperparâmetros próprios nem uma busca adicional. Com quatro votantes e duas classes pode haver empate de 2 a 2, resolvido em favor do menor rótulo (classe 0), o comportamento do `VotingClassifier` do scikit-learn.

5.3 Protocolo de avaliação: validação cruzada 30×10 com ajuste interno

A Figura 4 ilustra o protocolo, executado da mesma forma para as duas versões da base:

1. A base é dividida em 10 folds estratificados; o procedimento é repetido 30 vezes com permutações diferentes (`RepeatedStratifiedKFold`, semente 42), totalizando 300 pares (aprendizagem, teste), com 4.140 ou 4.141 exemplos de aprendizagem e 460 ou 461 de teste.
2. Em cada par, o fold de teste é posto de lado. Os 9 folds de aprendizagem são divididos em 5 folds estratificados (`StratifiedKFold`, semente 42), e cada combinação de hiperparâmetros da grade é avaliada pela F-measure macro média nesses 5 folds (`GridSearchCV`). Escolhe-se a combinação de maior média; em caso de empate, a primeira da grade.
3. O modelo é treinado novamente nos 9 folds de aprendizagem com a combinação escolhida e avaliado uma única vez no fold de teste, nas quatro métricas.
4. O voto majoritário é montado com os quatro modelos do passo 3, retreinado nos 9 folds e avaliado no mesmo fold de teste.

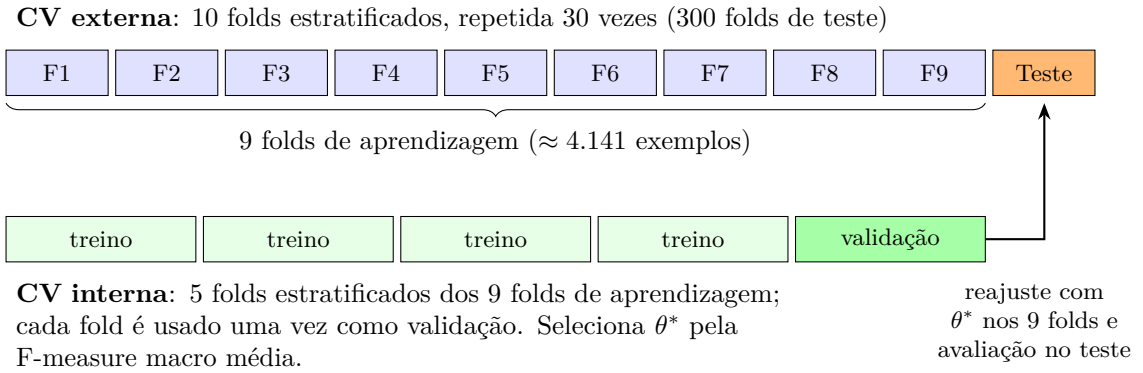


Figura 4: Validação cruzada com ajuste interno de hiperparâmetros. O fold de teste não participa da escolha de θ^* nem do ajuste da padronização.

Por fold externo são 45 combinações de hiperparâmetros (1 do gaussiano, 33 do k-NN, 6 da janela de Parzen e 5 da regressão logística) avaliadas em 5 folds internos, isto é, 67.500 ajustes internos por versão da base, além dos reajustes. Como as mesmas partições externas e internas valem para todos os classificadores, a comparação é pareada, e o ajuste interno evita o viés de seleção que surgiria se se reportasse a melhor média da busca como estimativa de desempenho [5], [6]; a Tabela 8 mostra que, na versão `kstar_classes`, essa média interna chega a superar a F-measure de teste em mais de um ponto percentual.

5.4 Métricas

Em cada fold de teste calculam-se a taxa de erro (1−acurácia) e as versões macro da precisão, da cobertura (*recall*) e da F-measure (F_1), isto é, a média simples dos valores de cada classe [19]. A média macro foi escolhida porque dá o mesmo peso às duas classes: em `kstar_classes`, a taxa de erro e as médias ponderadas seriam dominadas pelo grupo P_1 e quase não distinguiriam um bom classificador do que sempre prediz P_1 (erro de 0,74 %, F-measure macro de aproximadamente 0,50), razão pela qual a F-measure macro também foi adotada como critério de seleção de hiperparâmetros.

5.5 Obtenção dos hiperparâmetros

A Tabela 7 lista as grades: a do k-NN inclui valores ímpares de k (sem empate de votos com duas classes) espaçados de forma aproximadamente geométrica e as três distâncias pedidas no enunciado, enquanto as de h e C cobrem várias ordens de grandeza. O código descarta os valores de k maiores que o menor conjunto de treino interno, mas isso não chegou a ocorrer: mesmo no menor caso (115 exemplos, nas curvas de aprendizagem com 5 % da versão `kstar_classes`), todos os valores da grade são válidos.

Tabela 7: Grades de hiperparâmetros. A seleção usa a F-measure macro média na CV interna de 5 folds.

Classificador	Hiperparâmetros e valores candidatos	Combinações
Bayesiano gaussiano	nenhum (estimativas de máxima verossimilhança; $\varepsilon = 10^{-6}$ fixo)	1
Bayesiano k-NN	$k \in \{1, 3, 5, 7, 11, 15, 21, 31, 45, 63, 91\}$; distância $\in$ {euclidiana, city-block, Chebyshev}	33
Janela de Parzen	$h \in \{0{,}1;\ 0{,}5;\ 1;\ 2;\ 5;\ 10\}$	6
Regressão logística	$C \in \{0{,}01;\ 0{,}1;\ 1;\ 10;\ 100\}$ (penalidade L_2, L-BFGS)	5
Voto majoritário	nenhum (usa os membros já ajustados no mesmo fold)	–

Como a busca é refeita em cada um dos 300 folds externos, cada classificador tem uma distribuição de valores escolhidos, resumida na Tabela 8 junto com a F-measure média da melhor

combinação na CV interna.

Tabela 8: Hiperparâmetros selecionados nos 300 folds externos (frequência entre parênteses) e F-measure macro média da combinação escolhida na CV interna. Para comparação, a F-measure média de teste está entre colchetes.

Classificador	`original_2_classes`	`kstar_classes`
Bayesiano k-NN	city-block: $k = 5$ (147), $k = 7$ (68), $k = 1$ (56), $k = 3$ (10); euclidiana: $k = 1$ (17), $k = 3$ (2). Interna 0,9086 [teste 0,9093]	euclidiana: $k = 1$ (191), $k = 11$ (16), $k = 3$ (15), outros (8); city-block: $k = 1$ (51), $k = 11$ (12), outros (7). Interna 0,9879 [teste 0,9722]
Janela de Parzen	$h = 1$ (205), $h = 2$ (95). Interna 0,8108 [teste 0,8221]	$h = 2$ (148), $h = 1$ (115), $h = 0{,}5$ (19), $h = 0{,}1$ (18). Interna 0,9504 [teste 0,9545]
Regressão logística	$C = 100$ (160), $C = 10$ (126), $C = 1$ (14). Interna 0,9226 [teste 0,9230]	$C = 1$ (163), $C = 0{,}1$ (126), $C = 10$ (10), $C = 100$ (1). Interna 0,9803 [teste 0,9762]
Bayesiano gaussiano	sem hiperparâmetros. Interna 0,8283 [teste 0,8284]	sem hiperparâmetros. Interna 0,8971 [teste 0,8952]

Algumas observações sobre as escolhas:

- **k-NN.** Na base original, a distância city-block foi escolhida em 281 dos 300 folds, com k entre 5 e 7 na maioria. A distância L_1 soma as diferenças em todas as coordenadas e é menos afetada que a euclidiana por uma única coordenada extrema, o que convém a atributos esparsos de cauda longa. Na versão `kstar_classes`, predominam $k = 1$ (242 folds) e a distância euclidiana (230): com apenas cerca de 30 exemplos da classe rara no treino, vizinhanças maiores passam a ser dominadas pela classe majoritária, e a distância euclidiana sobre atributos padronizados é a mesma geometria em que o double k-means definiu os rótulos y^* (Seção 4.5). A distância de Chebyshev, que considera só a maior diferença entre coordenadas, não foi escolhida em nenhum fold.
- **Janela de Parzen.** As escolhas ficam no meio da grade ($h \in \{1, 2\}$ em todos os folds da base original e em 263 da versão `kstar_classes`), longe dos extremos: janelas pequenas tornam a densidade concentrada nos pontos de treino e janelas grandes a tornam quase uniforme.
- **Regressão logística.** Na base original, a busca prefere regularização fraca ($C = 100$ em 160 folds, $C = 10$ em 126), e, como $C = 100$ é o limite superior da grade, valores maiores poderiam ter sido testados. Na versão `kstar_classes`, a regularização é mais forte ($C \leq 1$ em 289 folds), o que se explica pela separabilidade linear das duas classes dessa versão (Equação 3): em dados separáveis, a estimativa sem penalização não existe, porque os coeficientes crescem sem limite. Nesse caso é a penalização que define o hiperplano estimado, e a validação interna preferiu penalizações mais fortes que na base original.
- **Viés da seleção.** Na base original, a F-measure interna da combinação escolhida é praticamente igual à de teste, enquanto, na versão `kstar_classes`, a média interna do k-NN (0,9879) supera a de teste (0,9722), porque escolher o máximo entre 33 candidatos avaliados com poucos exemplos da classe rara favorece combinações com sorte na validação. É exatamente o otimismo que o protocolo da Seção 5.3 evita ao medir o desempenho num fold que não participou da seleção.

5.6 Estimativas pontuais e intervalos de confiança

Os 300 valores de cada métrica não são observações independentes: os folds de uma mesma repetição compartilham exemplos de treino, e as 30 repetições reutilizam os mesmos dados. Tratar os 300 valores como uma amostra independente subestimaria a variância e estreitaria artificialmente o intervalo [20], [21]. Por isso, para cada classificador e métrica, calculou-se primeiro a média $\bar{m}_r$ dos 10 folds de cada repetição r (que é, ela própria, uma estimativa por validação cruzada de 10 folds) e, a partir das 30 médias, a estimativa pontual e o intervalo de confiança de 95 % pela distribuição t de Student com 29 graus de liberdade:

$$\hat{m} = \frac{1}{30}\sum_{r=1}^{30} \bar{m}_r, \qquad \hat{m} \pm t_{0{,}975;\,29}\,\frac{s_{\bar{m}}}{\sqrt{30}}, \qquad t_{0{,}975;\,29} \approx 2{,}045, \tag{7}$$

em que $s_{\bar{m}}$ é o desvio-padrão amostral das 30 médias. As Tabelas 9 e 10 apresentam os resultados, e a Figura 5 a distribuição dos valores por fold.

Tabela 9: `original_2_classes`: estimativa pontual ± meia-amplitude do IC 95 % (30 repetições), com precisão, cobertura e F-measure em média macro e o melhor valor de cada métrica em negrito.

Classificador	Taxa de erro	Precisão	Cobertura	F-measure
Bayesiano gaussiano	0,1705 ± 0,0004	0,8362 ± 0,0004	0,8507 ± 0,0004	0,8284 ± 0,0004
Bayesiano k-NN	0,0855 ± 0,0009	0,9163 ± 0,0009	0,9046 ± 0,0010	0,9093 ± 0,0009
Janela de Parzen	0,1686 ± 0,0010	0,8254 ± 0,0011	0,8201 ± 0,0013	0,8221 ± 0,0011
Regressão logística	0,0730 ± 0,0004	0,9265 ± 0,0005	**0,9204 ± 0,0005**	0,9230 ± 0,0005
Voto majoritário	**0,0716 ± 0,0008**	**0,9331 ± 0,0007**	0,9174 ± 0,0009	**0,9238 ± 0,0009**

Tabela 10: `kstar_classes`: estimativa pontual ± meia-amplitude do IC 95 % (30 repetições), com precisão, cobertura e F-measure em média macro, a taxa de erro com cinco casas decimais e o melhor valor de cada métrica em negrito.

Classificador	Taxa de erro	Precisão	Cobertura	F-measure
Bayesiano gaussiano	0,00251 ± 0,00012	0,9540 ± 0,0079	0,8705 ± 0,0066	0,8952 ± 0,0065
Bayesiano k-NN	0,00078 ± 0,00005	0,9799 ± 0,0018	0,9729 ± 0,0030	0,9722 ± 0,0023
Janela de Parzen	0,00122 ± 0,00011	0,9737 ± 0,0045	0,9471 ± 0,0054	0,9545 ± 0,0043
Regressão logística	**0,00077 ± 0,00011**	0,9641 ± 0,0044	**0,9949 ± 0,0041**	**0,9762 ± 0,0040**
Voto majoritário	0,00080 ± 0,00009	**0,9962 ± 0,0022**	0,9490 ± 0,0045	0,9668 ± 0,0034

Na base original, os classificadores formam dois patamares: a regressão logística e o voto majoritário têm erro próximo de 7 % e F-measure de 0,923, com o k-NN logo abaixo (erro de 8,5 %), enquanto o gaussiano e a janela de Parzen têm erro próximo de 17 %. Entre os dois melhores, o voto majoritário tem a maior precisão e a regressão logística a maior cobertura. Na versão `kstar_classes`, as taxas de erro são todas muito menores que o erro trivial de 0,74 % (o melhor modelo erra, em média, cerca de 0,35 exemplo por fold de teste), e as diferenças aparecem sobretudo na cobertura: o gaussiano reconhece pior a classe rara (cobertura macro de 0,87), enquanto a regressão logística quase não a perde (0,995). Os intervalos são estreitos porque refletem apenas a variação devida à escolha das partições: como as 30 repetições usam a mesma base, eles não incorporam a variação que se teria com uma nova amostra de e-mails, e não existe estimador não viesado dessa variância a partir de uma única validação cruzada [22]. As amplitudes maiores em `kstar_classes` decorrem dos 3 ou 4 exemplos da classe rara por fold de teste, que tornam as métricas macro muito discretas.

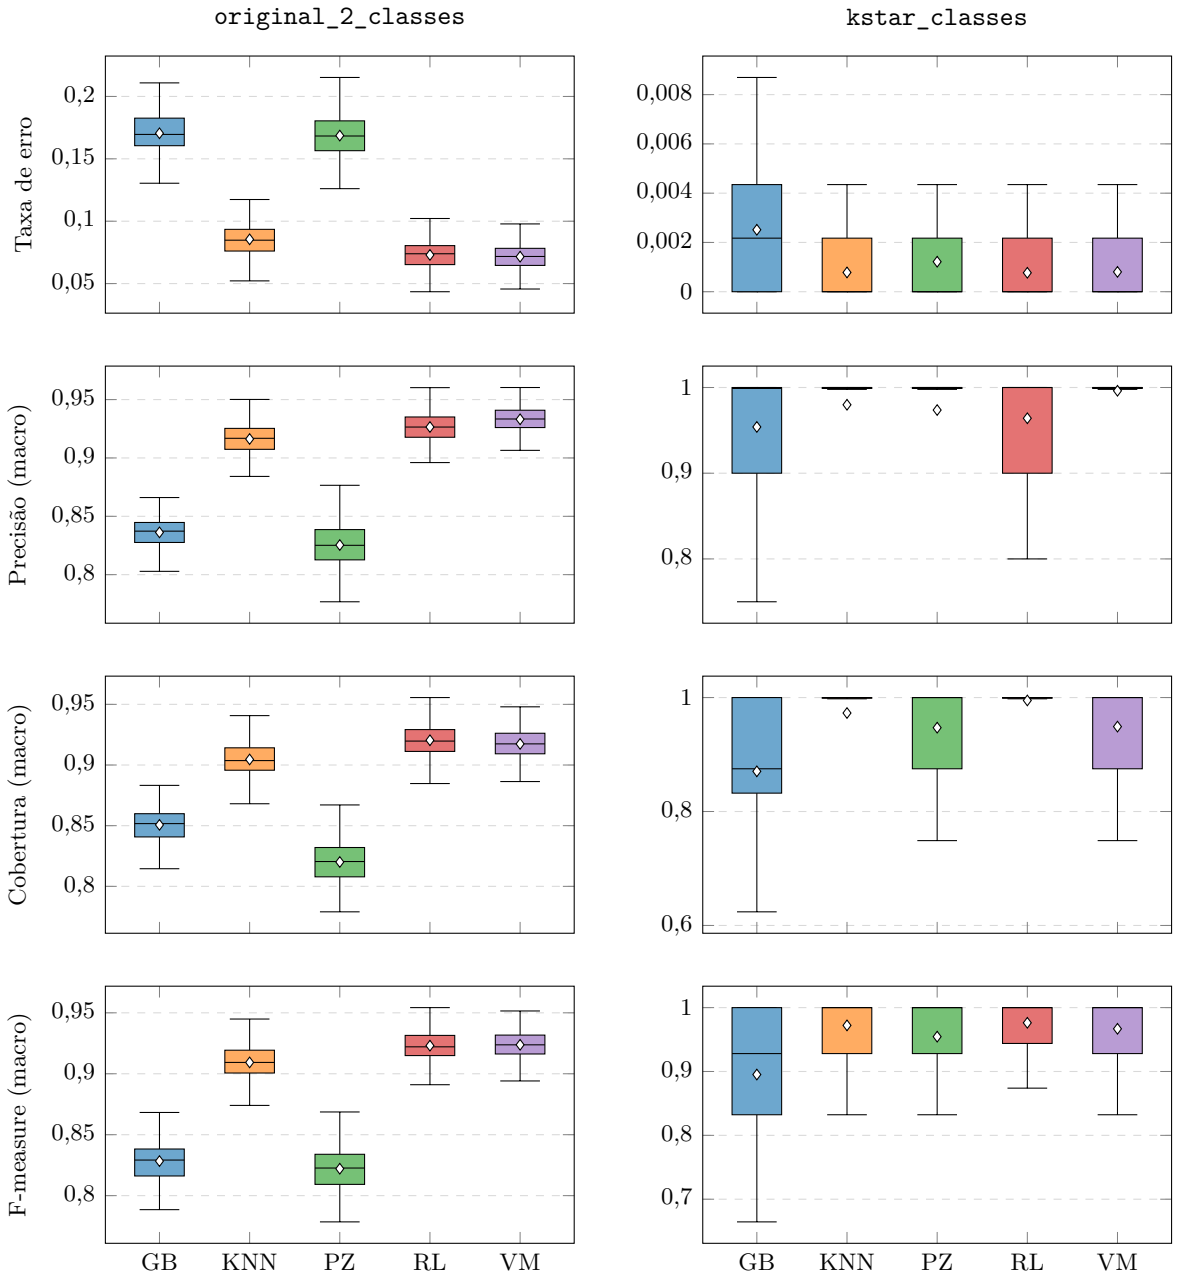


Figura 5: Distribuição das quatro métricas nos 300 folds de teste (colunas: versões da base; linhas: métricas; cada painel tem escala própria). A caixa vai do primeiro ao terceiro quartil, com a mediana; os bigodes vão até o fold mais extremo a no máximo 1,5 vez a distância interquartil da caixa, e os folds além deles não são desenhados. O losango marca a média, que fica fora da caixa quando há folds atípicos, como na precisão de `kstar_classes`. GB: gaussiano; KNN: k-NN; PZ: Parzen; RL: regressão logística; VM: voto majoritário.

5.7 Testes de Friedman e Nemenyi

Para cada versão da base e cada métrica, os cinco classificadores foram comparados pelo teste de Friedman [7], com os 300 folds externos como blocos. Em cada bloco, os classificadores recebem postos de 1 (melhor: menor erro ou maior precisão, cobertura ou F-measure) a 5, com postos médios em caso de empate. Com $N = 300$ blocos, $k = 5$ classificadores e R_j o posto médio do classificador j, a estatística

$$\chi^2_F = \frac{12N}{k(k+1)}\Big[\sum_{j=1}^{k} R_j^2 - \frac{k(k+1)^2}{4}\Big] \tag{8}$$

segue aproximadamente a distribuição χ^2 com $k-1 = 4$ graus de liberdade sob a hipótese nula de desempenho igual (usou-se `scipy.stats.friedmanchisquare`, que corrige os empates). Quando a hipótese nula é rejeitada com $\alpha = 0{,}05$, aplica-se o pós-teste de Nemenyi [23], [24]: dois classificadores diferem se seus postos médios diferem mais que a diferença crítica

$$\mathrm{CD} = q_\alpha \sqrt{\frac{k(k+1)}{6N}} = 2{,}728\sqrt{\frac{30}{1800}} \approx 0{,}352, \tag{9}$$

com $q_{0{,}05} = 2{,}728$ para $k = 5$ [24], e os p-valores par a par foram calculados com `scikit-posthocs`.

Tabela 11: Teste de Friedman ($N = 300$ blocos, 4 graus de liberdade; valor crítico $\chi^2_{0{,}95;4} = 9{,}49$).

Versão	Métrica	χ^2_F	p-valor	Decisão ($\alpha = 0{,}05$)
`original_2_classes`	Taxa de erro	1.017,59	$5{,}5 \times 10^{-219}$	rejeita H_0
	Precisão	1.033,16	$2{,}3 \times 10^{-222}$	rejeita H_0
	Cobertura	1.047,62	$1{,}7 \times 10^{-225}$	rejeita H_0
	F-measure	1.008,84	$4{,}3 \times 10^{-217}$	rejeita H_0
`kstar_classes`	Taxa de erro	265,55	$2{,}9 \times 10^{-56}$	rejeita H_0
	Precisão	176,75	$3{,}7 \times 10^{-37}$	rejeita H_0
	Cobertura	307,65	$2{,}4 \times 10^{-65}$	rejeita H_0
	F-measure	298,77	$2{,}0 \times 10^{-63}$	rejeita H_0

O teste de Friedman rejeitou a igualdade em todas as oito combinações (Tabela 11), e o pós-teste foi aplicado em todas. A Tabela 12 traz os postos médios, e a Tabela 13 os p-valores de Nemenyi para a F-measure.

Tabela 12: Postos médios no teste de Friedman (1 = melhor), com o menor posto de cada linha em negrito; diferenças maiores que CD = 0,352 são significativas pelo teste de Nemenyi ($\alpha = 0{,}05$).

Versão	Métrica	Gaussiano	k-NN	Parzen	Reg. logística	Voto maj.
`original_2_classes`	Taxa de erro	4,557	2,755	4,443	1,747	**1,498**
	Precisão	4,297	2,728	4,703	1,972	**1,300**
	Cobertura	4,077	2,745	4,923	**1,498**	1,757
	F-measure	4,387	2,758	4,613	1,702	**1,540**
`kstar_classes`	Taxa de erro	3,982	2,692	3,010	2,663	**2,653**
	Precisão	3,817	2,770	2,983	2,842	**2,588**
	Cobertura	4,080	2,650	3,027	**2,532**	2,712
	F-measure	4,063	2,643	3,033	**2,548**	2,712

Tabela 13: p-valores do pós-teste de Nemenyi para a F-measure macro, com os pares sem diferença significativa ($p \geq 0{,}05$) em negrito. GB: gaussiano; KNN: k-NN; PZ: Parzen; RL: regressão logística; VM: voto majoritário.

(a) `original_2_classes`

	GB	KNN	PZ	RL	VM
GB	—	$<10^{-4}$	**0,3998**	$<10^{-4}$	$<10^{-4}$
KNN		—	$<10^{-4}$	$<10^{-4}$	$<10^{-4}$
PZ			—	$<10^{-4}$	$<10^{-4}$
RL				—	**0,7205**
VM					—

(b) `kstar_classes`

	GB	KNN	PZ	RL	VM
GB	—	$<10^{-4}$	$<10^{-4}$	$<10^{-4}$	$<10^{-4}$
KNN		—	0,0212	**0,9481**	**0,9844**
PZ			—	0,0016	**0,0925**
RL				—	**0,7127**
VM					—

Para as demais métricas, os pares sem diferença significativa foram:

- `original_2_classes`: taxa de erro, GB–PZ ($p = 0{,}905$) e RL–VM ($p = 0{,}305$); precisão, nenhum (o voto majoritário é significativamente mais preciso que a regressão logística, $p < 10^{-5}$); cobertura, RL–VM ($p = 0{,}265$). Assim, gaussiano e Parzen empatam na taxa de erro e na F-measure, mas o gaussiano tem precisão ($p = 0{,}014$) e cobertura ($p < 10^{-9}$) macro significativamente maiores.
- `kstar_classes`: taxa de erro e precisão, KNN–PZ, KNN–RL, KNN–VM, PZ–RL e RL–VM; cobertura, KNN–RL, KNN–VM, PZ–VM e RL–VM. Em todas as métricas, o gaussiano difere de todos os demais.

Em resumo, na base original há três grupos estatisticamente distintos pela F-measure: {voto majoritário, regressão logística} no topo, o k-NN no meio e {gaussiano, Parzen} abaixo. Na versão `kstar_classes`, regressão logística, k-NN e voto majoritário não se distinguem, a janela de Parzen fica abaixo da regressão logística e do k-NN, e o gaussiano é o pior em todas as métricas.

Na interpretação desses resultados, é preciso considerar, em primeiro lugar, que o roteiro de Demšar [24] foi proposto para comparar classificadores em várias bases independentes, enquanto aqui os blocos são folds de uma única base, correlacionados entre si, e o grande número de blocos ($N = 300$) torna o teste muito sensível. Os p-valores extremamente pequenos indicam, portanto, que a ordenação dos classificadores é muito estável entre as partições da Spambase, e não que ela se generalize a outras bases. Em segundo lugar, comparações por postos médios dependem do conjunto de classificadores incluído [25], e por isso as conclusões acima são sempre lidas junto com as diferenças nas próprias métricas (Tabelas 9 e 10).

5.8 Curvas de aprendizagem

Protocolo. Para cada versão da base e cada proporção de treino $p \in \{5\%, 10\%, \ldots, 95\%\}$ (19 valores), a base completa foi dividida 10 vezes em treino (p) e teste ($1 - p$) por amostragem estratificada (`StratifiedShuffleSplit`, semente 42). Em cada divisão, os hiperparâmetros dos quatro classificadores de base foram escolhidos por validação cruzada estratificada usando apenas a parte de treino, com as mesmas grades e o mesmo critério da Seção 5.5; o voto majoritário usa os membros ajustados. O número de folds internos é $\min(5, n_{\min})$, em que $n_{\min}$ é o tamanho da

menor classe no treino: na versão `kstar_classes`, com 5 % e 10 % de treino há só 2 e 3 exemplos da classe rara, e a CV interna usa 2 e 3 folds. Calculou-se a F-measure macro tanto no conjunto de treino (resubstituição) quanto no de teste, totalizando $2 \times 19 \times 10 \times 5 = 1.900$ avaliações. As Figuras 6 e 7 mostram média $\pm$ 1 desvio-padrão das 10 divisões, e a Tabela 14 alguns pontos das curvas.

Tabela 14: F-measure macro média de treino / teste em algumas proporções de treino (10 divisões por proporção).

Classificador	5 %	10 %	25 %	50 %	75 %	95 %
`original_2_classes` (n_{treino}: 230, 460, 1.150, 2.300, 3.450, 4.370)						
Bayesiano gaussiano	0,904 / 0,842	0,872 / 0,836	0,843 / 0,830	0,833 / 0,829	0,830 / 0,829	0,831 / 0,829
Bayesiano k-NN	0,932 / 0,831	0,929 / 0,854	0,941 / 0,877	0,961 / 0,896	0,942 / 0,909	0,943 / 0,898
Janela de Parzen	0,915 / 0,683	0,930 / 0,710	0,991 / 0,766	0,985 / 0,795	0,986 / 0,810	0,993 / 0,814
Regressão logística	0,950 / 0,883	0,936 / 0,898	0,928 / 0,912	0,928 / 0,918	0,926 / 0,919	0,929 / 0,904
Voto majoritário	0,966 / 0,871	0,959 / 0,888	0,964 / 0,904	0,968 / 0,916	0,958 / 0,920	0,959 / 0,910
`kstar_classes` (exemplos da classe rara no treino: 2, 3, 8, 17, 25, 32)						
Bayesiano gaussiano	1,000 / 0,569	1,000 / 0,561	1,000 / 0,755	0,994 / 0,873	0,985 / 0,893	0,974 / 0,873
Bayesiano k-NN	0,950 / 0,895	1,000 / 0,956	0,997 / 0,950	0,995 / 0,971	0,997 / 0,968	1,000 / 0,990
Janela de Parzen	0,966 / 0,833	1,000 / 0,878	1,000 / 0,904	1,000 / 0,930	1,000 / 0,947	1,000 / 0,958
Regressão logística	0,866 / 0,869	1,000 / 0,927	0,997 / 0,950	1,000 / 0,964	1,000 / 0,962	1,000 / 0,980
Voto majoritário	0,950 / 0,789	1,000 / 0,888	1,000 / 0,914	1,000 / 0,946	1,000 / 0,972	1,000 / 0,966

Comentários: `original_2_classes`. As curvas separam os classificadores pelo compromisso entre viés e variância [15]:

- **Bayesiano gaussiano (viés alto).** As curvas de treino e teste convergem já com cerca de 25 % dos dados para o mesmo patamar, $F \approx 0{,}83$. A F-measure de teste é, na verdade, máxima com 5 % de treino (0,842) e cai levemente até 0,83, sem melhorar depois disso. Mais dados não ajudam, porque o erro vem do modelo: a normal multivariada descreve mal atributos esparsos, com excesso de zeros e caudas longas.
- **Janela de Parzen (variância alta).** A F-measure de treino fica perto de 0,99, enquanto a de teste parte de 0,68 e chega a 0,81. A grande distância entre as curvas indica sobreajuste: em 57 dimensões, um estimador de densidade não paramétrico precisa de muitos exemplos [26]. É também o modelo que mais ganha com o aumento da amostra (13 pontos percentuais entre 5 % e 90 %), e a curva de teste ainda sobe no fim.
- **k-NN.** A curva de teste cresce de 0,83 para cerca de 0,90–0,91, com distância entre treino e teste que diminui aos poucos: o método se beneficia do adensamento da amostra.
- **Regressão logística e voto majoritário.** São os melhores desde as menores amostras (F de teste de 0,88 e 0,87 com 5 %) e estabilizam perto de 0,92 a partir de cerca de 50 %. A regressão logística tem a menor distância entre treino e teste e o padrão clássico de um modelo linear regularizado: a F-measure de treino cai de 0,950 para 0,929 enquanto a de teste sobe. Em 95 %, a F-measure de teste cai um pouco e varia mais, porque o teste tem apenas 231 exemplos.

Comentários: `kstar_classes`. A tarefa de separar os 34 e-mails do grupo P_2 é mais fácil para os modelos locais e lineares: k-NN e regressão logística superam $F = 0{,}92$ no teste com apenas 10 % dos dados (3 exemplos da classe rara) e chegam a 0,98–0,99 no fim. O gaussiano é o que mais depende do tamanho da amostra: com 2 ou 3 exemplos da classe rara, a covariância estimada tem posto no máximo 1 ou 2 e a regularização $\varepsilon\mathbf{I}$ domina as demais direções; o modelo acerta todo o treino ($F = 1$) e generaliza mal ($F \approx 0{,}56$). A F-measure de teste sobe rapidamente até cerca de 50 % e depois oscila entre 0,83 e 0,93, com a maior distância para o treino entre

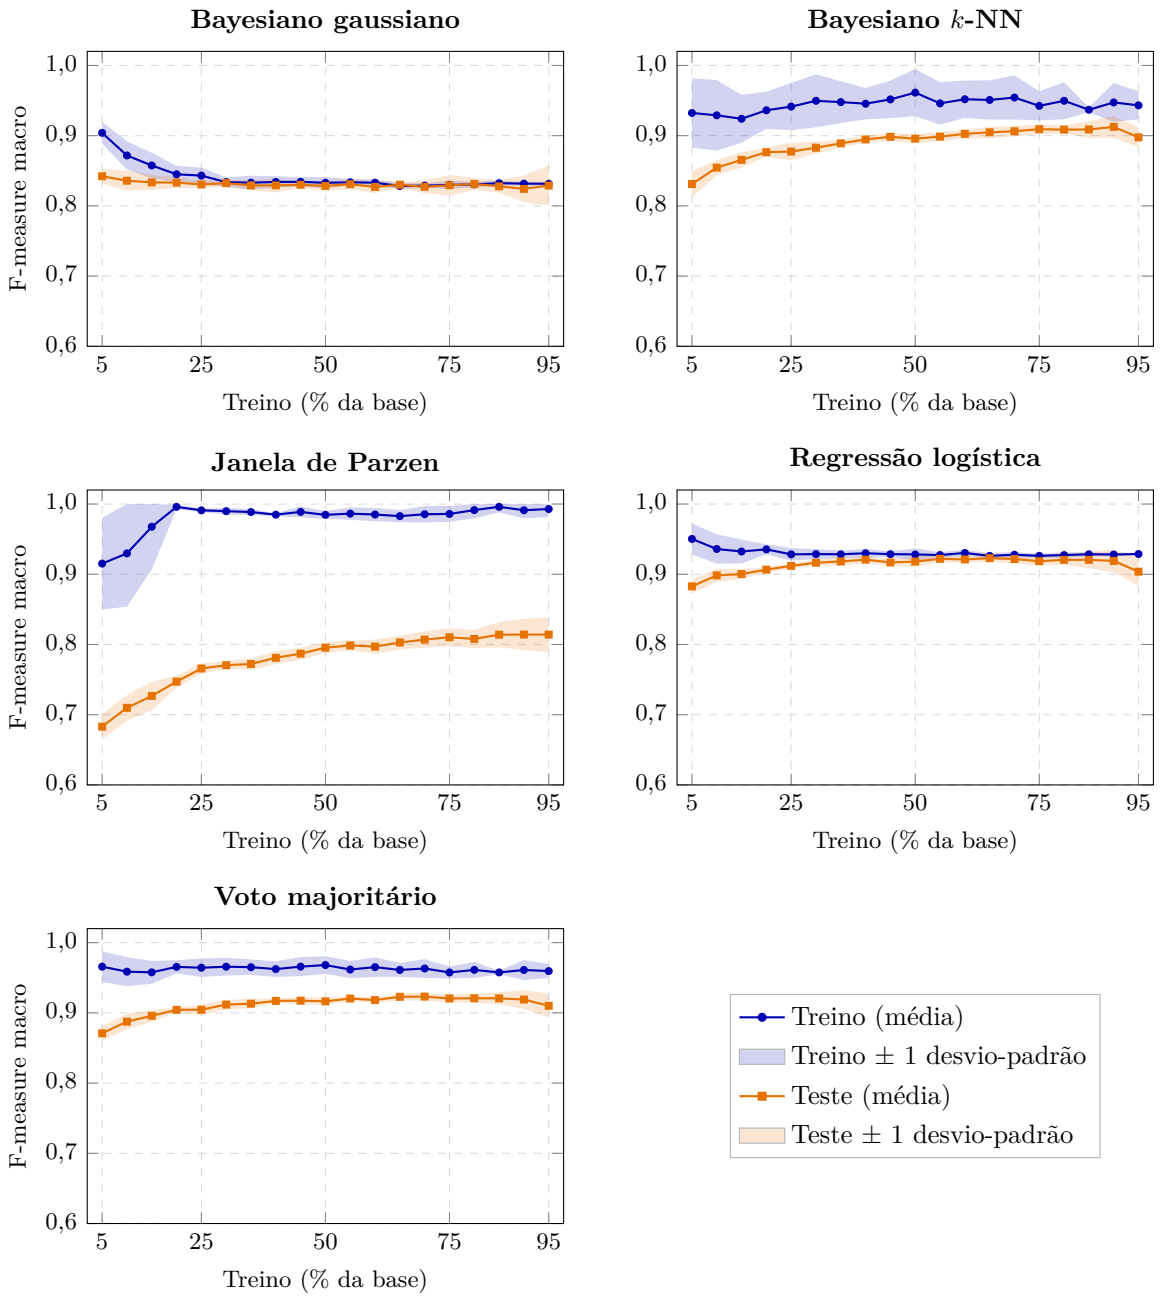


Figura 6: Curvas de aprendizagem na versão `original_2_classes`: F-measure macro de treino e de teste, média das 10 divisões estratificadas de cada proporção de treino, com faixa de ±1 desvio-padrão (limitada a 1) e a mesma escala em todos os painéis.

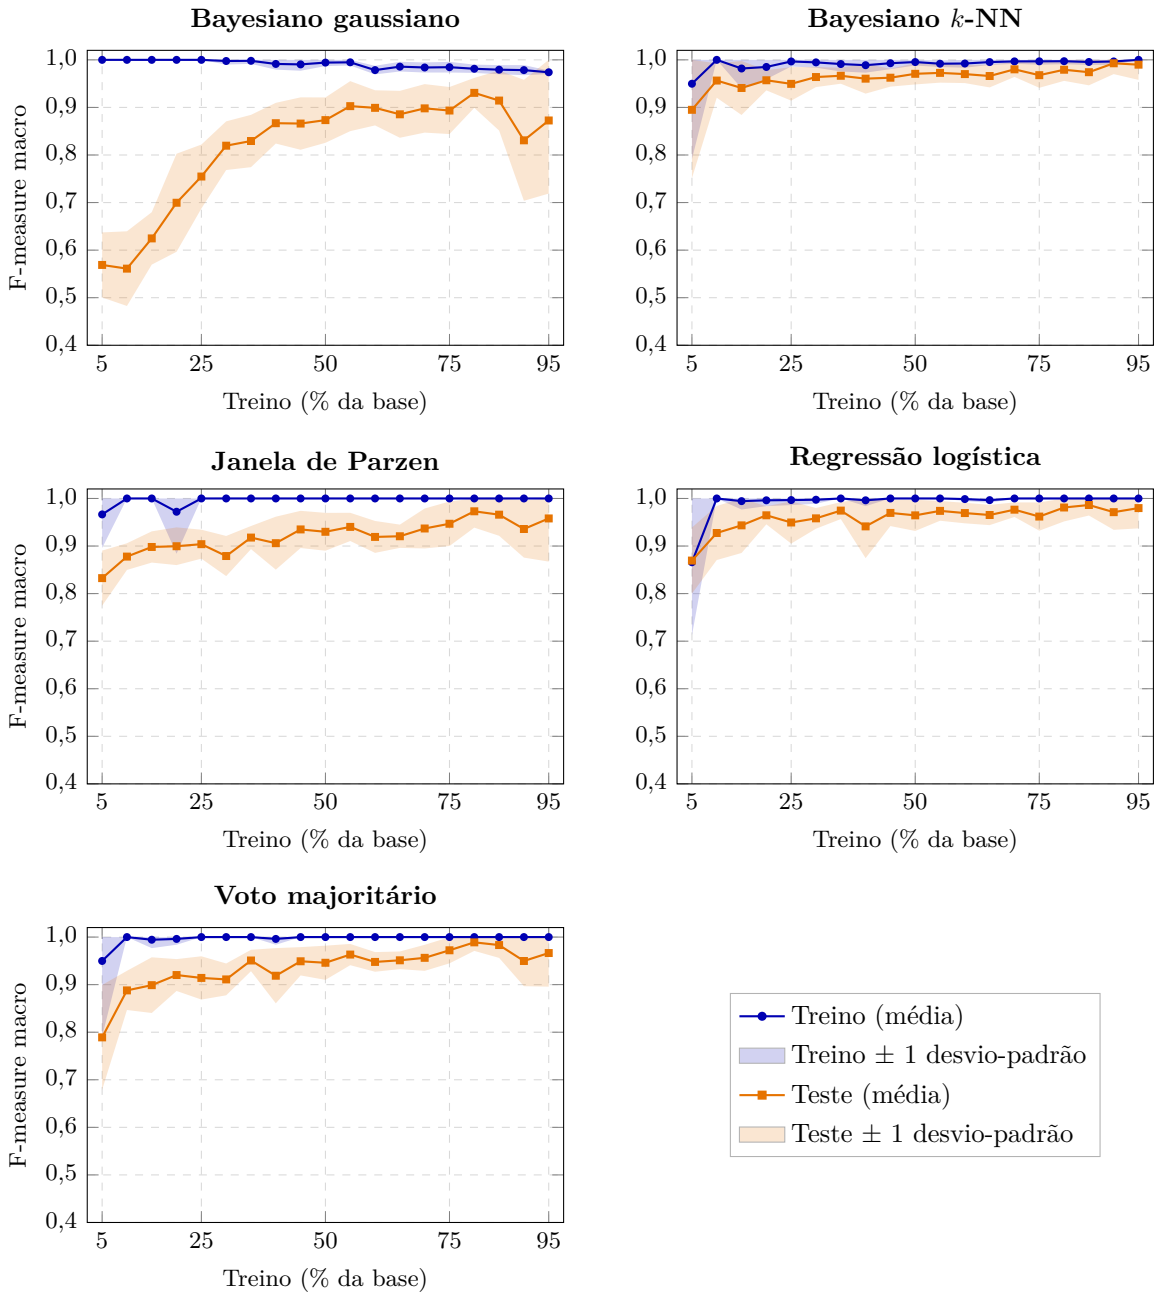


Figura 7: Curvas de aprendizagem na versão `kstar_classes`, com as mesmas convenções da Figura 6 e escala vertical a partir de 0,4.

os modelos, enquanto a janela de Parzen melhora, com oscilações, de 0,83 para 0,96. O voto majoritário parte de 0,79 com 5 %, abaixo de três dos seus membros, provavelmente porque, com o gaussiano errando muito a classe rara, os empates de 2 a 2 são resolvidos a favor da classe 0; ele alcança 0,97 com 75 %. Nas maiores proporções, o teste contém só 2 a 9 exemplos da classe rara, o que explica as faixas largas de desvio-padrão.

6 Discussão e limitações

A primeira limitação diz respeito à escolha de K^*, pois a silhueta selecionou uma partição dominada por 34 objetos atípicos (Seção 4.5), sem relação com as classes a priori, e é provável que uma transformação que reduza as caudas dos atributos antes do agrupamento, como $\log(1+x)$, ou um índice de validação menos sensível a grupos pequenos e isolados levasse a outra escolha; manteve-se, ainda assim, o critério definido no enunciado. Essa escolha determina a natureza da versão `kstar_classes`: como os rótulos y^* foram obtidos pelo agrupamento da base completa, a tarefa de classificação consiste em reproduzir uma regra de agrupamento conhecida, e não em prever um fenômeno externo. Essa regra é um hiperplano no espaço padronizado (Equação 3), o que favorece a regressão logística e o k-NN euclidiano, e, como a classe rara tem apenas 34 exemplos, as métricas macro de cada fold dependem de 3 ou 4 exemplos.

Algumas decisões de implementação dos classificadores também afetam os resultados, a começar pela janela de Parzen, cujo estimador recebe os atributos na escala original, com a mesma janela h em todas as dimensões. Como os desvios-padrão variam de 0,076 a 606, a distância no kernel é dominada pelos atributos `capital_run_length_*`, e uma janela de 1 ou 2 é larga demais para as frequências e estreita demais para as contagens de maiúsculas, o que provavelmente contribui para o desempenho fraco e o sobreajuste observados; a correção natural seria padronizar os atributos dentro do modelo, como no k-NN. No classificador gaussiano, o termo $\varepsilon\mathbf{I}$ é um desvio mínimo, mas real, da estimativa de máxima verossimilhança pedida no enunciado, que se justifica porque a densidade não está definida quando $\hat{\boldsymbol{\Sigma}}_i$ é singular. Na regressão logística, $C = 100$, o maior valor da grade, foi escolhido em 160 dos 300 folds da base original, de modo que uma grade mais ampla permitiria verificar se uma regularização ainda mais fraca traria ganho. Por fim, no voto majoritário, os empates de 2 a 2 entre os quatro votantes vão para a classe 0; na base original, essa regra favorece "não spam" e é compatível com o comitê ter a maior precisão e uma cobertura menor que a da regressão logística.

No protocolo de avaliação, por fim, as 391 linhas duplicadas foram mantidas, e uma cópia no treino e outra no teste é acertada trivialmente pelo k-NN com $k = 1$, escolhido em 73 folds da base original e em 242 da versão `kstar_classes`; essas estimativas são, portanto, levemente otimistas, sobretudo na classe rara de `kstar_classes`, em que só 28 dos 34 e-mails são distintos. Além disso, tanto os intervalos de confiança quanto os testes de Friedman e Nemenyi usam resultados de partições da mesma base e, por isso, subestimam a incerteza em relação a novas amostras (Seções 5.6 e 5.7), algo que alternativas como o teste t corrigido de Nadeau e Bengio [21] levam em conta; ao avaliarem a replicabilidade de vários testes, Bouckaert e Frank [27] optaram justamente por ele. Finalmente, seguindo o item d) do enunciado, as curvas de aprendizagem foram calculadas apenas para a F-measure, e as demais métricas não foram registradas nesse experimento.

7 Conclusões

Na Questão 1, as 900 execuções do double k-means convergiram pelo critério dos slides, e a silhueta das melhores execuções de cada par selecionou $(K^*, H^*) = (2, 2)$, com Sil = 0,6596, mais que o dobro do segundo maior valor. A partição obtida isola 34 e-mails legítimos que usam com frequência muito alta 11 palavras e números ligados à HP, origem dos e-mails não spam da base, e tem ARI $= -0{,}00495$ frente às classes spam/não spam, o que mostra que a estrutura geométrica

dominante na base padronizada não é a divisão entre spam e não spam, mas a separação de um pequeno grupo atípico. Esse resultado decorre tanto do critério de seleção quanto do próprio algoritmo, já que a silhueta, por ser uma média sobre todos os objetos, premia a separação de poucos pontos extremos, e a soma de quadrados do double k-means dá peso desproporcional às caudas longas dos atributos esparsos. Além disso, a análise da partição na convergência mostrou que a fronteira entre os dois grupos é um hiperplano no espaço padronizado (Equação 3), fato que antecipa o comportamento dos classificadores na segunda versão da base.

Na Questão 2, a validação cruzada estratificada 30×10 com ajuste interno de hiperparâmetros, aplicada da mesma forma aos cinco classificadores, mostrou que, na detecção de spam, o voto majoritário ($F = 0{,}9238$, erro de 7,2 %) e a regressão logística ($F = 0{,}9230$, erro de 7,3 %) são estatisticamente equivalentes e superiores aos demais, seguidos pelo k-NN com distância city-block ($F = 0{,}9093$), enquanto o gaussiano e a janela de Parzen ficaram abaixo ($F \approx 0{,}82$–$0{,}83$). Embora empatem na F-measure, os dois melhores modelos chegam a esse resultado por caminhos diferentes: o voto majoritário tem a maior precisão e a regressão logística a maior cobertura, diferença coerente com a regra de desempate do comitê a favor da classe não spam. As curvas de aprendizagem ajudam a explicar a ordenação, pois indicam que o gaussiano é limitado por viés, já que a normal multivariada descreve mal atributos esparsos e de cauda longa e mais dados não melhoram o seu desempenho, ao passo que a janela de Parzen é limitada por variância, com grande distância entre treino e teste em 57 dimensões e uma curva de teste que ainda sobe com 95 % dos dados. A regressão logística, por sua vez, tem bom desempenho desde as menores amostras e a menor distância entre treino e teste, o que, diante do empate estatístico com o voto majoritário, que exige ajustar quatro modelos, a torna a opção mais econômica para essa tarefa.

Na versão com os rótulos da Questão 1, regressão logística, k-NN e voto majoritário reproduzem quase perfeitamente a partição (F entre 0,967 e 0,976) e não se distinguem estatisticamente, resultado esperado porque a fronteira entre os grupos é linear e foi definida pela distância euclidiana nos atributos padronizados, a mesma geometria do k-NN escolhido na maioria dos folds. O gaussiano é o pior em todas as métricas, prejudicado por uma classe rara com menos exemplos de treino que atributos, cuja covariância estimada é singular sem o termo $\varepsilon\mathbf{I}$. Como essa versão mede a capacidade de reproduzir uma regra de agrupamento, e não de prever um fenômeno externo, os seus resultados não devem ser lidos como evidência da utilidade prática dos classificadores.

Do ponto de vista metodológico, a separação entre seleção e avaliação mostrou-se necessária, pois, na versão `kstar_classes`, a F-measure interna da combinação escolhida para o k-NN (0,9879) supera a de teste (0,9722), um otimismo que teria sido reportado como desempenho caso a mesma validação servisse para escolher e para avaliar os modelos. A comparação pareada nas mesmas 300 partições, por sua vez, deu aos testes de Friedman e Nemenyi grande poder para ordenar os classificadores, embora os p-valores reflitam a estabilidade dessa ordenação dentro da Spambase, e não a sua generalização para outras bases. Como continuação, as limitações da Seção 6 apontam caminhos diretos: repetir o agrupamento após uma transformação que reduza as caudas dos atributos, padronizar os atributos dentro da janela de Parzen, ampliar a grade de C da regressão logística e substituir os intervalos e testes por procedimentos que considerem a dependência entre folds, como o teste t corrigido de Nadeau e Bengio [21].

Referências

[1] M. Vichi, “Double k-means clustering for simultaneous classification of objects and variables,” in *Advances in Classification and Data Analysis*, ser. Studies in Classification, Data Analysis, and Knowledge Organization, S. Borra, R. Rocci, M. Vichi, and M. Schader, Eds., Berlin, Heidelberg: Springer, 2001, pp. 43–52. DOI: 10.1007/978-3-642-59471-7_6.

[2] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *Journal of Computational and Applied Mathematics*, vol. 20, pp. 53–65, 1987. DOI: 10.1016/0377-0427(87)90125-7.

[3] L. Hubert and P. Arabie, "Comparing partitions," *Journal of Classification*, vol. 2, no. 1, pp. 193–218, 1985. DOI: 10.1007/BF01908075.

[4] M. Hopkins, E. Reeber, G. Forman, and J. Suermondt, *Spambase*, UCI Machine Learning Repository, 1999. DOI: 10.24432/C53G6X. [Online]. Available: https://archive.ics.uci.edu/dataset/94/spambase.

[5] S. Varma and R. Simon, "Bias in error estimation when using cross-validation for model selection," *BMC Bioinformatics*, vol. 7, p. 91, 2006. DOI: 10.1186/1471-2105-7-91.

[6] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.

[7] M. Friedman, "The use of ranks to avoid the assumption of normality implicit in the analysis of variance," *Journal of the American Statistical Association*, vol. 32, no. 200, pp. 675–701, 1937. DOI: 10.1080/01621459.1937.10503522.

[8] R. Kohavi, "A study of cross-validation and bootstrap for accuracy estimation and model selection," in *Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI)*, 1995, pp. 1137–1144.

[9] G. Govaert and M. Nadif, *Co-Clustering: Models, Algorithms and Applications*. London: ISTE and Wiley, 2013. DOI: 10.1002/9781118649480.

[10] J. A. Hartigan and M. A. Wong, "Algorithm AS 136: A k-means clustering algorithm," *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, vol. 28, no. 1, pp. 100–108, 1979. DOI: 10.2307/2346830.

[11] L. Kaufman and P. J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster Analysis*. New York: Wiley, 1990.

[12] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

[13] R. O. Duda, P. E. Hart, and D. G. Stork, *Pattern Classification*, 2nd ed. New York: Wiley-Interscience, 2001.

[14] O. Ledoit and M. Wolf, "A well-conditioned estimator for large-dimensional covariance matrices," *Journal of Multivariate Analysis*, vol. 88, no. 2, pp. 365–411, 2004. DOI: 10.1016/S0047-259X(03)00096-4.

[15] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer, 2009.

[16] T. M. Cover and P. E. Hart, "Nearest neighbor pattern classification," *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, 1967. DOI: 10.1109/TIT.1967.1053964.

[17] E. Parzen, "On estimation of a probability density function and mode," *The Annals of Mathematical Statistics*, vol. 33, no. 3, pp. 1065–1076, 1962. DOI: 10.1214/aoms/1177704472.

[18] L. I. Kuncheva, *Combining Pattern Classifiers: Methods and Algorithms*, 2nd ed. Hoboken: Wiley, 2014.

[19] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009. DOI: 10.1016/j.ipm.2009.03.002.

[20] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Computation*, vol. 10, no. 7, pp. 1895–1923, 1998. DOI: 10.1162/089976698300017197.

[21] C. Nadeau and Y. Bengio, "Inference for the generalization error," *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003. DOI: 10.1023/A:1024068626366.

[22] Y. Bengio and Y. Grandvalet, "No unbiased estimator of the variance of k-fold cross-validation," *Journal of Machine Learning Research*, vol. 5, pp. 1089–1105, 2004.

[23] P. B. Nemenyi, "Distribution-free multiple comparisons," Ph.D. dissertation, Princeton University, 1963.

[24] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *Journal of Machine Learning Research*, vol. 7, pp. 1–30, 2006.

[25] A. Benavoli, G. Corani, and F. Mangili, "Should we really use post-hoc tests based on mean-ranks?" *Journal of Machine Learning Research*, vol. 17, no. 5, pp. 1–10, 2016.

[26] B. W. Silverman, *Density Estimation for Statistics and Data Analysis*. London: Chapman and Hall, 1986.

[27] R. R. Bouckaert and E. Frank, "Evaluating the replicability of significance tests for comparing learning algorithms," in *Advances in Knowledge Discovery and Data Mining (PAKDD 2004)*, ser. Lecture Notes in Computer Science, vol. 3056, Springer, 2004, pp. 3–12. DOI: 10.1007/978-3-540-24775-3_3.

A Reprodução dos resultados

Os experimentos usaram o arquivo `dataset/spambase.data` do repositório UCI, cujo resumo SHA-256 é

`b1ef93de71f97714d3d7d4f58fc9f718da7bbc8ac8a150eff2778616a8097b12`.

Na raiz do repositório, com as dependências instaladas por `poetry install`, os comandos abaixo, nesta ordem, geram todos os resultados usados no relatório:

1. `poetry run python -m src.experiments.question_1`
   900 execuções do double k-means e melhor execução de cada par (K, H) (`results/q1_*`).
2. `poetry run python -m src.analysis.silhouette`
   Silhueta dos 9 vencedores e escolha de (K^*, H^*) (`results/silhouette_scores.csv`).
3. `poetry run python -m src.analysis.clustering_evaluation`
   ARI, matriz $\mathbf{G}$, contingência e rótulos y^* (`results/q1_object_labels.csv`).
4. `poetry run python -m src.experiments.question_2 --n-jobs -1`
   Validação cruzada 30×10 com ajuste interno (`results/q2/cv_30x10_results.csv`).
5. `poetry run python -m src.analysis.statistical_analysis`
   IC 95 %, Friedman e Nemenyi (arquivos em `results/`).
6. `poetry run python docs/relatorio/gerar_boxplots.py`
   Estatísticas dos *boxplots* da Figura 5 (`docs/relatorio/dados/boxplots.csv`).
7. `poetry run python -m src.experiments.learning_curves --n-jobs -1`
   Curvas de aprendizagem (arquivos em `results/` e `plots/`).

Para compilar este relatório: `latexmk -pdf relatorio.tex` no diretório `docs/relatorio`.